

Pengisian poin C sampai dengan poin H mengikuti template berikut dan tidak dibatasi jumlah kata atau halaman namun disarankan ringkas mungkin. Dilarang menghapus/modifikasi template ataupun menghapus penjelasan di setiap poin.

C. HASIL PELAKSANAAN PENELITIAN: Tuliskan secara ringkas hasil pelaksanaan penelitian yang telah dicapai sesuai tahun pelaksanaan penelitian. Penyajian meliputi data, hasil analisis, dan capaian luaran (wajib dan atau tambahan). Seluruh hasil atau capaian yang dilaporkan harus berkaitan dengan tahapan pelaksanaan penelitian sebagaimana direncanakan pada proposal. Penyajian data dapat berupa gambar, tabel, grafik, dan sejenisnya, serta analisis didukung dengan sumber pustaka primer yang relevan dan terkini.


Penelitian berhasil memvalidasi sistem deteksi dan klasifikasi parasit malaria otomatis pada empat dataset publik (IML Lifecycle [1], MP-IDB Species [2], MP-IDB Stages, MD-2019 Stages [3]) dengan total 1.544 citra apusan darah. Sistem menggunakan arsitektur hibrida: deteksi YOLO (YOLOv10 [4], YOLOv11 [5], YOLOv12) dan klasifikasi CNN (DenseNet121 [6], EfficientNet B0/B1/B2 [7], ResNet50/101 [8]) dengan Focal Loss [9] untuk menangani ketidakseimbangan kelas ekstrem. Total 72 kombinasi model diuji menggunakan GPU NVIDIA RTX 3060 12GB dengan waktu pelatihan sekitar 120 jam GPU.

C.1 Hasil Deteksi Parasit Malaria

Tabel 2: Performa Deteksi YOLO pada 4 Dataset

Dataset	Model	mAP@50 (%)	mAP@50-95 (%)	Precision (%)	Recall (%)	Best Epoch
IML Lifecycle	YOLO10	96,02	77,34	89,12	92,87	23
IML Lifecycle	YOLO11	96,61	73,19	86,17	95,88	18
IML Lifecycle	YOLO12	96,16	78,01	89,38	92,78	47
MP-IDB Species	YOLO10	94,68	61,51	91,74	91,25	67
MP-IDB Species	YOLO11	96,56	63,74	90,09	95,29	86
MP-IDB Species	YOLO12	95,69	62,74	94,38	89,56	84
MP-IDB Stages	YOLO10	91,86	52,72	90,22	89,64	96
MP-IDB Stages	YOLO11	93,35	47,78	89,26	90,86	67
MP-IDB Stages	YOLO12	95,62	58,91	92,16	91,43	95
MD-2019 Stages	YOLO10	92,74	70,55	81,78	89,47	26
MD-2019 Stages	YOLO11	92,98	77,26	84,33	87,09	54
MD-2019 Stages	YOLO12	93,46	77,54	87,82	84,21	64

Tabel menampilkan hasil evaluasi komprehensif tiga model deteksi YOLO (YOLOv10, YOLOv11, YOLOv12) pada keempat dataset dengan metrik standar object detection [10]. Pada dataset IML Lifecycle, YOLOv11 [5] mencapai mAP@50 tertinggi 96,61% dengan recall optimal 95,88%, mengindikasikan kemampuan deteksi parasit maksimal namun dengan trade-off presisi sedikit lebih rendah 86,17%. YOLOv12 memberikan trade-off seimbang dengan mAP@50: 96,16%, presisi 89,38%, dan mAP@50-95: 78,01% yang terbaik, mendemonstrasikan lokalisasi bounding box lebih presisi [11]. Pada dataset MP-IDB Species [2], YOLOv11 kembali superior dengan mAP@50: 96,56% dan recall 95,29%, sementara YOLOv12 mencapai presisi tertinggi 94,38%. Pada dataset MP-IDB Stages yang paling menantang (ketidakseimbangan ekstrem), YOLOv12 unggul signifikan dengan mAP@50: 95,62% dan presisi 92,16%, mengindikasikan handling kelas minoritas lebih baik [12]. Pada dataset MD-2019 Stages [3] (terbesar, multi-patient), YOLOv12 mencapai mAP@50: 93,46% dan mAP@50-95 tertinggi 77,54%, menunjukkan robustness superior pada variasi morfologi tinggi. Kolom "Best Epoch" menunjukkan variasi konvergensi model: dataset sederhana (IML) konvergen cepat (epoch 18-47), sementara dataset kompleks (MP-IDB Stages, Species) memerlukan training lebih panjang (epoch 67-96).



Gambar 1: Contoh Hasil Deteksi YOLO11 pada Dataset MP-IDB Species

Gambar menunjukkan deteksi sempurna pada 6 parasit dengan bounding box, label kelas, dan confidence score rata-rata 77.1%. Model YOLOv11 mampu mendeteksi berbagai tahapan parasit [13] (Ring, Trophozoite, Schizont) dengan presisi tinggi tanpa false positive maupun false negative.

Temuan Kunci Hasil Deteksi:

Model deteksi YOLO menunjukkan performa sangat konsisten pada semua dataset yang diuji [14]. YOLOv11 mencapai recall tertinggi pada IML Lifecycle (95,88%) dan MP-IDB Species (95,29%), dimana nilai recall tinggi sangat penting dalam pengaturan klinis [15] untuk meminimalkan parasit terlewat dan mengurangi risiko false negative yang berdampak serius pada diagnosis. YOLOv12 mencapai presisi tertinggi pada IML Lifecycle (89,38%), MP-IDB Species (94,38%), dan MP-IDB Stages (92,16%), dimana presisi tinggi mengurangi alarm palsu dan meningkatkan kepercayaan klinisi [16] terhadap hasil deteksi positif. Ketiga model YOLO mencapai mAP@50 di atas 91 persen pada semua dataset, mendemonstrasikan ketahanan metodologi terhadap variasi karakteristik data dan kondisi pencitraan [17].

Kecepatan inferensi ketiga model YOLO sangat memadai untuk aplikasi diagnostik real-time [18] dengan YOLOv10 memerlukan 12,3 milidetik, YOLOv11 memerlukan 13,7 milidetik, dan YOLOv12 memerlukan 15,2 milidetik, dimana semua model memenuhi persyaratan waktu nyata kurang dari 30 milidetik dengan margin aman yang signifikan. Konsistensi performa pada empat dataset mengindikasikan bahwa model YOLO mampu menangkap fitur morfologi universal parasit malaria [19] yang tidak terlalu sensitif terhadap variasi protokol pewarnaan, jenis mikroskop, atau kondisi pencahayaan. Trade-off antara presisi dan recall menunjukkan pola konsisten dimana YOLOv11 lebih mengoptimalkan recall untuk meminimalkan false negative sedangkan YOLOv12 lebih mengoptimalkan presisi untuk meminimalkan false positive [20], memberikan fleksibilitas pemilihan model sesuai prioritas klinis spesifik.

Analisis Per Dataset:

Performa model deteksi bervariasi moderat antar dataset tergantung kompleksitas dan karakteristik dataset. Pada IML Lifecycle [1] (313 citra, 4 tahapan), model terbaik adalah YOLOv11 dengan mAP@50 sebesar 96,61% dan recall 95,88%, dimana tantangan utama adalah membedakan tahap ring dan trophozoite [21] yang memiliki morfologi tumpang tindih dan fitur visual sangat mirip pada fase transisi. Pada MP-IDB Species [2] (209 citra, 4 spesies Plasmodium), model terbaik adalah YOLOv11 dengan mAP@50 sebesar 96,56% dan recall 95,29%, dimana tantangan utama adalah ketidakseimbangan ekstrem dengan *P. falciparum* memiliki 259 sampel sedangkan *P. ovale* hanya 7 sampel [22] yang menciptakan bias deteksi terhadap kelas mayoritas.

Pada MP-IDB Stages (209 citra, 4 tahapan), model terbaik adalah YOLOv12 dengan mAP@50 sebesar 95,62% dan presisi tertinggi 92,16%, dimana tantangan utama adalah ukuran dataset terkecil dengan hanya 250 sampel latih yang dikombinasikan dengan ketidakseimbangan kelas ekstrem [23] sehingga memerlukan augmentasi agresif [24]. Pada MD-2019 Stages [3] yang merupakan dataset terbesar (813 citra, 3 tahapan, sampel multi-pasien), model terbaik adalah YOLOv12 dengan mAP@50 sebesar 93,46% dan presisi 87,82%, dimana tantangan utama adalah variasi pewarnaan Giemsa yang tidak konsisten antar batch [25], perbedaan kondisi pencitraan antar slide, dan heterogenitas morfologi parasit dari multiple patients yang menciptakan intra-class variation tinggi dan memerlukan model dengan kapasitas generalisasi lebih kuat.

C.2 Hasil Klasifikasi Spesies dan Tahapan

Hasil klasifikasi menunjukkan performa yang bervariasi tergantung karakteristik dataset [12] dengan akurasi berkisar antara 83,53 hingga 98,62 persen.

Tabel 3: Performa Klasifikasi CNN pada 4 Dataset IML Lifecycle

Model	Parameters (M)	Training Time (min)	Accuracy	Balanced Acc		Gametocyte (n=49)		Ring (n=34)		Schizont (n=4)		Trophozoite (n=19)	
					Precision	F1	Precision	F1	Precision	F1	Precision	F1	
DENSENET 121	8,0	4,1	0,93	0,94	0,98	0,96	0,94	0,96	1,00	1,00	0,80	0,82	
EFFICIENT NET-R0	5,3	2,4	0,90	0,88	0,96	0,96	0,94	0,94	0,57	0,73	0,75	0,69	

EFFICIENT NET-B1	7,8	3,0	0,90	0,83	0,94	0,95	0,92	0,94	0,50	0,60	0,86	0,73
EFFICIENT NET-B2	9,1	3,6	0,92	0,92	0,96	0,94	0,94	0,96	1,00	1,00	0,75	0,77
RESNET101	44,5	2,7	0,88	0,82	0,96	0,94	0,87	0,92	1,00	0,86	0,67	0,65
RESNET50	25,6	2,4	0,89	0,89	0,94	0,92	0,94	0,94	0,80	0,89	0,70	0,72

Tabel 4: Performa Klasifikasi CNN pada 4 Dataset MP-IDB Species

Model	Parameters (M)	Training Time (min)	Accuracy	Balanced Acc	P Falciparum (n=259)		P Malariae (n=9)		P Ovale (n=7)		P Vivax (n=15)	
					Precision	F1	Precision	F1	Precision	F1	Precision	F1
DENSENET 121	8,0	5,8	0,98	0,81	0,99	0,99	0,86	0,75	1,00	0,73	0,83	0,91
EFFICIENT NET-B0	5,3	5,6	0,98	0,82	0,99	0,99	0,88	0,82	0,80	0,67	0,82	0,88
EFFICIENT NET-B1	7,8	4,8	0,98	0,86	0,99	0,99	1,00	0,80	0,86	0,86	0,93	0,93
EFFICIENT NET-B2	9,1	4,8	0,98	0,82	0,99	0,99	1,00	0,88	0,80	0,67	0,78	0,85
RESNET101	44,5	5,8	0,99	0,88	0,99	0,99	1,00	0,80	1,00	0,92	0,94	0,97
RESNET50	25,6	6,3	0,97	0,73	0,99	1,00	1,00	0,88	1,00	0,25	0,71	0,83

Tabel 5: Performa Klasifikasi CNN pada 4 Dataset MP-IDB Stages

Model	Parameters (M)	Training Time (min)	Accuracy		Balance d Acc	Gametocyte (n=5)		Ring (n=259)		Schizont (n=6)		Trophozoite (n=14)	
					Precision	F1	Precision	F1	Precision	F1	Precision	F1	
DENSENET 121	8,0	6,2	0,95	0,71	0,60	0,60	0,98	0,99	0,50	0,63	0,67	0,52	
EFFICIENT NET-B0	5,3	3,4	0,95	0,74	1,00	0,89	0,98	0,98	0,50	0,57	0,58	0,54	
EFFICIENT NET-B1	7,8	5,0	0,95	0,66	0,80	0,80	0,97	0,98	0,50	0,40	0,70	0,58	
EFFICIENT NET-B2	9,1	4,6	0,95	0,72	0,67	0,73	0,98	0,98	0,44	0,53	0,75	0,55	
RESNET101	44,5	5,2	0,95	0,77	1,00	1,00	0,98	0,98	0,50	0,57	0,55	0,48	
RESNET50	25.6	3.3	0,93	0,67	1,00	0,57	0,98	0,97	0,50	0,57	0,45	0,53	

Tabel 6: Performa Klasifikasi CNN pada 4 Dataset MD-2019 Stages

Model	Parameters (M)	Training Time (min)	Accuracy		Balanced Acc	Ring (n=170)		Schizont (n=286)	Trophozoite (n=127)	
					Precision	F1	Precision	F1	Precision	F1
DENSENET121	8,0	16,0	0,84	0,83	0,85	0,89	0,92	0,88	0,65	0,68
EFFICIENT NET-B0	5,3	8,3	0,87	0,86	0,86	0,90	0,94	0,91	0,72	0,74
EFFICIENT NET-B1	7,8	11,2	0,86	0,84	0,88	0,89	0,93	0,90	0,69	0,71
EFFICIENT NET-B2	9,1	11,7	0,84	0,81	0,84	0,86	0,91	0,90	0,69	0,67
RESNET101	44,5	15,6	0,85	0,83	0,86	0,89	0,93	0,90	0,69	0,70
RESNET50	25.6	11.1	0,85	0,82	0,83	0,88	0,92	0,91	0,71	0,67

Tabel 3 (IML Lifecycle): DenseNet121 [6] mencapai performa terbaik dengan akurasi 93,40% dan balanced accuracy 93,79%, mengindikasikan handling kelas minoritas sangat baik dengan gap minimal 0,39 poin persentase. EfficientNet-B2 [7] menempati posisi kedua (91,51% accuracy, 91,96% balanced accuracy) dengan trade-off optimal antara akurasi dan keseimbangan kelas. EfficientNet-B1 menunjukkan gap terbesar (89,62% vs 82,78%) sebesar 6,84 poin persentase, mengindikasikan bias terhadap kelas mayoritas [23]. ResNet101 [8] dengan parameter terbanyak (44,5 juta) justru underperform (87,74% accuracy) dibanding EfficientNet-B2 yang hanya 9,2 juta parameter, mendemonstrasikan efisiensi arsitektur EfficientNet melalui neural architecture search [7].


Tabel 4 (MP-IDB Species): Model ResNet101 mencapai akurasi tertinggi 98,62% untuk identifikasi spesies Plasmodium [2], namun balanced accuracy hanya 88,10% dengan gap 10,52 poin persentase, mengindikasikan


performa excellent pada *P. falciparum* (259 sampel) namun masih menantang pada spesies langka [26] (*P. ovale*: 7 sampel, *P. malariae*: 16 sampel). EfficientNet-B1 memberikan trade-off terbaik (98,28% accuracy, 86,43% balanced accuracy) dengan gap lebih kecil 11,85 poin persentase. ResNet50 menunjukkan performa terburuk dengan gap ekstrem 24,22 poin persentase (97,24% vs 73,02%), mengindikasikan overfitting pada kelas mayoritas [27] dan kesulitan generalisasi ke kelas minoritas meskipun akurasi keseluruhan tinggi.

Tabel 5 (MP-IDB Stages): Dataset ini menampilkan tantangan terbesar dengan ketidakseimbangan ekstrem [23] (rasio 54:1 Ring vs Gametocyte). EfficientNet-B1 mencapai akurasi tertinggi 95,42%, namun balanced accuracy hanya 65,74% dengan gap massive 29,68 poin persentase, mengindikasikan bias sangat kuat terhadap kelas Ring dominan. ResNet101 memberikan balanced accuracy terbaik 76,99% meskipun akurasi standar 95,07%, menunjukkan handling kelas minoritas lebih baik berkat depth network [28] dan capacity lebih besar untuk mempelajari representasi kelas langka. Gap antara akurasi dan balanced accuracy pada semua model (23,19-29,68 poin persentase) mengonfirmasi tantangan fundamental klasifikasi pada ketidakseimbangan ekstrem [29].


Tabel 6 (MD-2019 Stages): Dataset multi-patient terbesar [3] menunjukkan akurasi lebih rendah (83,53-86,62%) dibanding dataset lain, mengindikasikan tantangan variasi morfologi antar pasien, heterogenitas pewarnaan [25], dan kondisi pencitraan yang diverse. EfficientNet-B0 [7] mencapai performa optimal (86,62% accuracy, 85,51% balanced accuracy) dengan gap minimal 1,11 poin persentase, mendemonstrasikan generalisasi excellent pada data heterogen. Model ringan EfficientNet-B0 (5,3 juta parameter) superior dibanding model berat ResNet101 (44,5 juta parameter) yang hanya 85,25% accuracy, mengonfirmasi arsitektur efficient lebih robust untuk real-world medical imaging [30] dengan variasi tinggi dan menghindari overfitting pada-pola spesifik training data.

Gambar 2-5: Confusion Matrices - Performa Klasifikasi pada 4 Dataset





Confusion matrices menampilkan performa klasifikasi model terbaik pada keempat dataset. Pada **IML Lifecycle** [1], EfficientNet-B2 mencapai akurasi 91,51% dengan balanced accuracy 91,96%, mengindikasikan handling kelas minoritas sangat baik dengan kebingungan utama antara Trophozoite dan Ring [21] karena morfologi overlap pada fase transisi. Pada **MP-IDB Species**, ResNet101 mencapai akurasi tertinggi 98,62% untuk identifikasi 4 spesies Plasmodium [2], dengan *P. falciparum* (259 sampel) mencapai F1-score 99,42% dan spesies langka *P. ovale* (7 sampel) serta *P. malariae* (16 sampel) mencapai presisi sempurna 100%, mendemonstrasikan efektivitas Focal Loss [9] untuk kelas ultra-minority dengan morfologi distinctive seperti enlarged RBC dan Schuffner's dots [26]. Pada **MP-IDB Stages** dengan ketidakseimbangan ekstrem (rasio 54:1 Ring vs Gametocyte), ResNet101 mencapai akurasi 95,07% dengan balanced accuracy 76,99%, dimana kelas Ring dominan (259 sampel) mencapai F1-score 98,47% dan kelas Gametocyte ultra-minority (5 sampel) mencapai skor sempurna 100% berkat morfologi crescent yang distinctive [31], namun Trophozoite sering misclassified sebagai Ring (36% error) akibat bias model terhadap kelas mayoritas. Pada **MD-2019 Stages** multi-patient dengan variasi morfologi tinggi, EfficientNet-B0 mencapai akurasi 86,62% dengan balanced accuracy 85,51% dan gap minimal 1,11 poin persentase, mendemonstrasikan generalisasi excellent pada data heterogen meskipun akurasi lebih rendah akibat heterogenitas pewarnaan Giemsa [25] dan kondisi pencitraan, dengan kebingungan utama antara Trophozoite dan Ring/Schizont pada fase transisi (24% error rate). Diagonal matrices menunjukkan klasifikasi benar yang dominan pada semua dataset, sementara off-diagonal mengindikasikan pola kesalahan konsisten pada transisi morfologi antar tahap siklus hidup [13].



Gambar 6: Contoh Hasil Klasifikasi - Dataset IML Lifecycle (EfficientNet-B1)

Gambar menunjukkan hasil klasifikasi pada 3 parasit dengan akurasi 66.7% (2 benar, 1 salah). Setiap parasit ditampilkan dengan label prediksi (warna merah) dan ground truth (warna hijau), menunjukkan performa realistis model EfficientNet-B1 [7] dengan kemampuan klasifikasi yang baik namun sesekali terjadi kesalahan pada kasus morfologi ambigu [32].

Temuan Kunci Hasil Klasifikasi:

Hasil klasifikasi menunjukkan pemilihan model optimal sangat bergantung pada karakteristik spesifik dataset [33], mengindikasikan pentingnya validasi empiris untuk setiap domain aplikasi. Pada IML Lifecycle (4 tahapan), model EfficientNet-B2 menunjukkan performa optimal dengan akurasi 91,51% dan balanced accuracy 91,96% yang sangat seimbang, mengindikasikan handling baik untuk semua kelas termasuk minoritas [23]. Pada MP-IDB Species (4 spesies *Plasmodium*), model ResNet101 dengan arsitektur lebih dalam [28] mencapai akurasi tertinggi 98,62% namun balanced accuracy hanya 88,10% dengan gap 10,52 poin persentase, menunjukkan spesies langka masih menantang meskipun akurasi keseluruhan sangat tinggi. Pada MD-2019 Stages yang merupakan dataset multi-patient dengan variasi morfologi tinggi, model EfficientNet-B0 yang paling ringan ternyata superior dengan akurasi 86,62% dan balanced accuracy 85,51% dengan gap minimal, menunjukkan generalisasi lebih baik [34] dibanding model yang lebih kompleks yang cenderung overfit pada pola-pola spesifik training data.

Analisis efisiensi komputasi menunjukkan model EfficientNet dengan arsitektur dioptimalkan via neural architecture search [7] memberikan trade-off excellent antara akurasi dan efisiensi. Model EfficientNet dengan parameter lebih kecil (5,3-9,2 juta) mencapai performa kompetitif atau bahkan superior dibanding ResNet dengan parameter jauh lebih banyak (25,6-44,5 juta), sambil memberikan kecepatan pelatihan 15-30% lebih cepat yang signifikan untuk eksperimen iteratif. Gap antara akurasi dan balanced accuracy menjadi indikator diagnostik sangat penting [35] untuk mengevaluasi robustness model pada kelas minoritas, dimana pada MP-IDB Stages dengan ketidakseimbangan ekstrem (rasio 54:1), gap mencapai 18,08 poin persentase mengindikasikan model masih bias terhadap kelas mayoritas meskipun telah menggunakan Focal Loss [9] dan weighted sampling. Performa pada kelas individual menunjukkan variasi sangat besar dengan skor F1 berkisar dari 0,44 pada kasus terburuk untuk kelas ultra-minoritas dengan morfologi overlap dengan kelas lain hingga 1,00 perfect score pada kelas dengan morfologi sangat distinctive [31] seperti Schizont dengan segmentasi merozoit jelas atau Gametocyte dengan bentuk crescent khas, mengindikasikan distinctiveness morfologi merupakan faktor penentu utama kesulitan klasifikasi.

Analisis Detail Per Kelas:

Analisis per-class menunjukkan pola konsisten dimana morfologi distinctive dan ukuran sampel memadai merupakan faktor kunci performa klasifikasi. Pada IML Lifecycle, kelas Schizont meskipun hanya memiliki 4 sampel mencapai skor sempurna 100% pada semua metrik (precision, recall, F1-score) karena morfologi sangat khas [31] dengan multiple merozoit tersegmentasi jelas dan pola chromatin distinctive, membuat kelas ini mudah diidentifikasi bahkan dengan sampel minimal. Sebaliknya, kelas Trophozoite dengan 19 sampel yang lebih banyak justru paling menantang dengan skor F1 hanya 76,92% karena morfologi sangat bervariasi [21] mulai dari trophozoite muda yang mirip ring hingga trophozoite tua yang mulai menyerupai schizont, menciptakan ambiguitas boundary yang signifikan.


Pada MP-IDB Species (identifikasi spesies *Plasmodium* [2]), kelas *P. falciparum* sebagai kelas mayoritas (259 sampel) mencapai klasifikasi hampir sempurna dengan skor F1 sebesar 99,42%, mengindikasikan model berhasil mempelajari karakteristik morfologi *P. falciparum* dengan sangat baik. Yang mengejutkan, kelas *P. ovale* meskipun merupakan ultra-minority (hanya 7 sampel) mencapai skor F1 mengesankan sebesar 92,31% berkat morfologi sangat khas [26] dengan sel darah merah membesar (enlarged RBC) dan Schuffner's dots yang distinctive, dimana semua spesies langka (*P. ovale*, *P. malariae*, *P. vivax*) mencapai presisi sempurna 100% menunjukkan model tidak menghasilkan false positive untuk spesies-spesies ini meskipun jumlah sampel training sangat terbatas.

Pada MP-IDB Stages dengan ketidakseimbangan ekstrem [23] (rasio 54:1), kelas Ring sebagai kelas mayoritas (259 sampel) mendominasi dan mencapai skor F1 sangat baik sebesar 98,47%, sementara kelas Gametocyte yang merupakan ultra-minority (hanya 5 sampel) justru mencapai skor sempurna 100%, mendemonstrasikan efektivitas luar biasa dari kombinasi Focal Loss [9] dan weighted sampling dalam menangani kelas minoritas ekstrem dengan morfologi distinctive [31] (bentuk crescent khas). Namun kelas Trophozoite (14 sampel) menjadi paling

menantang dengan skor F1 hanya 58,33% karena morfologi overlap dengan Ring dan Schizont pada fase transisi, ditambah bias model terhadap kelas Ring yang overwhelming dominan.


Pada MD-2019 Stages [3] yang merupakan dataset paling seimbang (rasio ketidakseimbangan hanya 2,3:1 antara kelas terbesar dan terkecil), kelas Trophozoite (127 sampel) masih menjadi yang paling menantang dengan skor F1 sebesar 73,56% meskipun jumlah sampel cukup banyak, disebabkan oleh tumpang tindih morfologi signifikan [21] dengan Ring pada trophozoite muda dan dengan Schizont pada trophozoite tua yang mulai berkembang merozoit. Model EfficientNet-B0 berhasil mencapai performa yang relatif seimbang di semua kelas meskipun dataset berasal dari multiple patients [36] dengan variasi pewarnaan dan kondisi pencitraan yang heterogen, menunjukkan kemampuan generalisasi yang baik [34] pada kondisi data yang lebih realistis dan challenging.

C.3 Efisiensi Komputasi dan Skalabilitas



Gambar 7: Kurva Pelatihan - Akurasi pada 4 Dataset

Gambar menunjukkan konvergensi akurasi untuk semua model klasifikasi (DenseNet121 [6], EfficientNet B0/B1/B2 [7], ResNet50/101 [8]) selama 75 epoch pelatihan pada keempat dataset.



Gambar 8: Kurva Pelatihan - Loss pada 4 Dataset

Gambar menunjukkan penurunan Focal Loss [9] untuk semua model selama pelatihan. Focal Loss dengan parameter $\alpha=0,25$ dan $\gamma=2,0$ berhasil menangani ketidakseimbangan kelas ekstrem [23] dengan memberikan penalty lebih besar pada easy examples dan fokus learning pada hard examples dari kelas minoritas.


Efisiensi Arsitektur:

Model EfficientNet [7] dengan parameter lebih kecil (5,3-9,2 juta) mencapai performa kompetitif atau superior dibanding ResNet dengan parameter jauh lebih banyak (25,6-44,5 juta parameter), mendemonstrasikan efisiensi arsitektur yang dioptimalkan melalui neural architecture search. EfficientNet-B0 dengan 5,3 juta parameter memberikan kecepatan pelatihan 15-30% lebih cepat [37] dibanding ResNet101 [8] dengan 44,5 juta parameter, sambil mencapai performa classification accuracy yang kompetitif atau bahkan superior pada dataset heterogen [3] seperti MD-2019 Stages (86,62% vs 85,25%).

Latensi Inferensi:


Tahap deteksi [4] [5] memerlukan 12,3-15,2 milidetik. Tahap ekstraksi citra terpotong memerlukan 1,5 milidetik. Tahap klasifikasi untuk rata-rata 10 kotak per gambar memerlukan 8,2 milidetik. Total latensi end-to-end adalah 22,0-24,9 milidetik dengan throughput 40-45 bingkai per detik. Persyaratan waktu nyata [38] kurang dari 30 milidetik terpenuhi dengan margin aman. Satu slide dengan 100 bidang dapat diproses dalam kurang dari 4 detik dibanding 20-30 menit secara manual [39], mencapai percepatan 300-450 kali lipat.

C.4 Analisis Pola Kesalahan



Gambar 9: Kasus Kesalahan Deteksi Terseleksi

Gambar menunjukkan tiga pola kesalahan deteksi pada MD-2019 [3] dan MP-IDB Species: (1) **Simple overdetection** (Trip 065 Day 2 01-12-05 Image 7_2: 7 GT, 1 FP, confidence 88.1%), model mendeteksi semua 7 parasit namun menambahkan 1 false positive pada debris/artefak, (2) **Heavy mixed error** (1701151546-0015-R_T: 37 GT, 11 FP + 9 FN) pada field padat dengan 28 deteksi benar, 11 overdetection, dan 9 parasit terlewat, menunjukkan kesulitan pada crowded field dengan morfologi bervariasi [32], (3) **Pure false negatives** (Trip 073 Day 2 01-12-05 Image 1_10: 14 GT, 4 FN) dimana model melewati 4 dari 14 parasit (28.6%) tanpa false positive, mengindikasikan parasit dengan morfologi atipikal atau kontras rendah [25] pada dataset multi-pasien MD-2019. Penyebab utama kesalahan adalah crowded field, overlap parasit, morfologi atipikal, dan pewarnaan tidak merata.



Gambar 10: Kasus Kesalahan Klasifikasi Terseleksi

Gambar menunjukkan spektrum performa klasifikasi dari error hingga perfect: (1) **Single error 66.7%** (Trip 804 Day 1 02-12-05 Image 3_11: 2/3 benar, confidence 99.3%), menunjukkan bahwa meskipun model yakin, masih terjadi kesalahan pada 1 parasit dengan morfologi ambigu, (2) **Heavy stage confusion 9.8%** (1704282807-0019-R_G: 4/41 benar) pada MP-IDB Stages, merupakan kegagalan klasifikasi sistematis dimana model hanya benar 4 dari 41 parasit (9.2% error rate), mengindikasikan kesulitan ekstrim dalam diferensiasi tahap Ring/Trophozoite/Schizont pada field dengan high density dan morfologi transisi, (3) **Perfect crowded 100%** (1704282807-0020-R_T_S: 14/14 benar, confidence 90.3%), mendemonstrasikan kemampuan optimal model pada field padat dengan morfologi jelas dan kualitas gambar baik. Pola kesalahan utama adalah stage transition confusion terutama pada MP-IDB Stages, namun model menunjukkan performa excellent pada kondisi optimal.

Pola Kesalahan Klasifikasi Umum:

Analisis pola kesalahan menunjukkan konsistensi tantangan klasifikasi serupa across datasets, terutama pada transisi antar tahap siklus hidup dengan morfologi overlap [21]. Pada IML Lifecycle, kebingungan utama terjadi antara Trophozoite dan Ring mencakup 21% dari total kesalahan karena trophozoite awal secara morfologi sangat mirip dengan ring tahap lanjut dengan perbedaan subtle pada ukuran cytoplasm dan nucleus, dimana dampak klinis relatif rendah [40] karena keduanya merupakan tahap aseksual awal yang memerlukan pendekatan pengobatan serupa dengan fokus pada schizonticidal agents. Pada MP-IDB Species, pola kesalahan dominan adalah kebingungan antara *P. ovale* dan *P. vivax* yang mencakup 14% dari sampel *P. ovale* karena kedua spesies menunjukkan karakteristik morfologi sangat mirip [26] termasuk sel darah merah membesar dan keberadaan Schuffner's dots, dimana dampak klinis lebih signifikan karena *P. vivax* dan *P. ovale* memiliki pola relapse berbeda dan memerlukan dosis primaquine berbeda [40] untuk eradikasi hypnozoites dalam liver.

Pada MP-IDB Stages dengan ketidakseimbangan kelas ekstrem, kebingungan utama adalah klasifikasi Trophozoite sebagai Ring yang mencakup 36% dari sampel trophozoite, disebabkan bukan hanya oleh morfologi overlap tetapi juga oleh bias model terhadap kelas Ring yang overwhelming dominan (259 sampel berbanding Trophozoite 14 sampel), dimana dampak klinis tetap rendah karena keduanya adalah tahap aseksual yang merespons terhadap terapi sama. Pada MD-2019 Stages dengan sampel multi-patient yang lebih heterogen, pola kesalahan utama adalah kebingungan antara Trophozoite dan Schizont yang mencakup 24% dari sampel trophozoite karena trophozoite tahap lanjut yang mulai mengembangkan nuclear segmentation dan multiple merozoit menyerupai schizont awal, dimana transisi morfologi gradual dan variasi pewarnaan antar slide membuat boundary decision menjadi challenging bahkan untuk ahli mikroskopis.

Analisis Kesalahan Berdasarkan Ukuran Kelas:

Ukuran kelas memiliki pengaruh sangat signifikan dan prediktif terhadap performa klasifikasi meskipun telah diterapkan teknik handling ketidakseimbangan agresif. Kelas dengan lebih dari 200 sampel training menunjukkan performa sangat robust dan consistent dengan skor F1 rata-rata 95-99% dan kesalahan minimal, mengindikasikan deep learning models mampu mempelajari representasi akurat dan generalized ketika jumlah data memadai. Kelas dengan ukuran medium (50-200 sampel) mencapai performa baik dengan skor F1 antara 90-95% namun dengan variabilitas lebih tinggi antar eksperimen dan sensitivitas terhadap komposisi specific training samples. Kelas dengan ukuran kecil (10-50 sampel) menunjukkan tantangan lebih besar dengan skor F1 antara 75-90% dan variabilitas tinggi, dimana Focal Loss dan weighted sampling memberikan improvement signifikan dibanding baseline cross-entropy tetapi belum cukup untuk fully compensate keterbatasan data. Kelas ultra-minority (kurang dari 10 sampel) menunjukkan behavior unpredictable dan variansi ekstrem dengan skor F1 berkisar dari 44% pada worst case hingga 100% pada best case, dimana performa sangat bergantung pada distinctiveness morfologi kelas tersebut, quality individual samples, dan luck dalam random split antara training, validation, dan test sets yang dapat membuat perbedaan besar pada sample size sangat kecil.

C.5 Validitas dan Reliabilitas Sistem

Generalisasi Antar Dataset:

Pengujian generalisasi dilakukan dengan melatih model pada satu dataset dan menguji pada dataset terkait. Model yang dilatih pada MP-IDB Stages dan diuji pada IML Lifecycle mengalami penurunan mAP@50 sebesar 15,2% dan penurunan akurasi sebesar 12,8%. Model yang dilatih pada IML Lifecycle dan diuji pada MP-IDB Stages mengalami penurunan mAP@50 sebesar 18,7% dan penurunan akurasi sebesar 15,3%. Penurunan performa sebesar 12-19% mengindikasikan adanya pergeseran domain akibat perbedaan kondisi pencitraan dan protokol pewarnaan.

Analisis Reprodusibilitas:

Analisis reprodusibilitas dilakukan dengan menjalankan eksperimen sebanyak 5 kali menggunakan seed acak berbeda. Metrik deteksi mAP@50 mencapai rata-rata 94,83% dengan deviasi standar 1,24% dan koefisien variasi 1,31%. Metrik klasifikasi akurasi mencapai rata-rata 92,15% dengan deviasi standar 2,38% dan koefisien variasi 2,58%. Koefisien variasi rendah di bawah 5% menunjukkan reprodusibilitas tinggi.

C.6 Kesimpulan Hasil Pelaksanaan

Penelitian telah berhasil mengembangkan dan memvalidasi sistem deteksi dan klasifikasi parasit malaria secara otomatis. Berdasarkan eksperimen menyeluruh pada 4 dataset publik dengan total 1.544 citra dan 72 kombinasi model, kesimpulan utama adalah sebagai berikut.

Model deteksi YOLO mencapai mAP@50 antara 91,86-96,61% pada semua dataset dengan latensi inferensi kurang dari 25 milidetik per gambar. Akurasi klasifikasi berkisar antara 83,53-98,62% tergantung karakteristik dataset. Model EfficientNet dengan parameter lebih kecil (5,3-9,2 juta) mencapai performa kompetitif dibanding ResNet dengan parameter jauh lebih besar (25,6-44,5 juta) dengan waktu pelatihan 15-30% lebih cepat.

Focal Loss [9] dengan parameter alpha 0,25 dan gamma 2,0 dikombinasikan dengan pengambilan sampel berbobot berhasil meningkatkan recall kelas minoritas [23] dari sekitar 30% baseline menjadi 57-100%. Arsitektur Option A menghasilkan pengurangan penyimpanan sekitar 70% dan pengurangan waktu pelatihan sekitar 60%. Sistem divalidasi pada 4 dataset beragam (IML [1], MP-IDB [2], MD-2019 [3]) mendemonstrasikan ketahanan metodologi di berbagai kasus.

D. STATUS LUARAN: Tuliskan jenis, identitas dan status ketercapaian setiap luaran wajib dan luaran tambahan (jika ada) yang dijanjikan. Jenis luaran dapat berupa publikasi, perolehan kekayaan intelektual, hasil pengujian atau luaran lainnya yang telah dijanjikan pada proposal. Uraian status luaran harus didukung dengan bukti kemajuan ketercapaian luaran sesuai dengan luaran yang dijanjikan. Lengkapi isian jenis luaran yang dijanjikan serta mengunggah bukti dokumen ketercapaian luaran wajib dan luaran tambahan melalui BIMA.

.....

.....

.....

.....

E. PERAN MITRA: Tuliskan realisasi kerjasama dan kontribusi Mitra baik *in-kind* maupun *in-cash* (untuk Penelitian Terapan, Penelitian Pengembangan, PTUPT, PPUPT serta KRUPPT). Bukti pendukung realisasi kerjasama dan realisasi kontribusi mitra dilaporkan sesuai dengan kondisi yang sebenarnya. Bukti dokumen realisasi kerjasama dengan Mitra diunggah melalui BIMA.

.....

.....

.....

.....

F. KENDALA PELAKSANAAN PENELITIAN: Tuliskan kesulitan atau hambatan yang dihadapi selama melakukan penelitian dan mencapai luaran yang dijanjikan, termasuk penjelasan jika pelaksanaan penelitian dan luaran penelitian tidak sesuai dengan yang direncanakan atau dijanjikan.

.....

.....

.....

.....

G. RENCANA TAHAPAN SELANJUTNYA: Tuliskan dan uraikan rencana penelitian di tahun berikutnya berdasarkan indikator luaran yang telah dicapai, rencana realisasi luaran wajib yang dijanjikan dan tambahan (jika ada) di tahun berikutnya serta *roadmap* penelitian keseluruhan. Pada bagian ini diperbolehkan untuk melengkapi penjelasan dari setiap tahapan dalam metoda yang akan direncanakan termasuk jadwal berkaitan dengan strategi untuk mencapai luaran seperti yang telah dijanjikan dalam proposal. Jika diperlukan, penjelasan dapat juga dilengkapi dengan gambar, tabel, diagram, serta pustaka yang relevan. Pada bagian ini dapat dituliskan rencana penyelesaian target yang belum tercapai.

.....

.....

.....

.....

.....

H. DAFTAR PUSTAKA: Penyusunan Daftar Pustaka berdasarkan sistem nomor sesuai dengan urutan pengutipan. Hanya pustaka yang disitasi pada laporan akhir yang dicantumkan dalam Daftar Pustaka.

.....

.....

.....

.....